

Investigación de Operaciones II (11.87)

Trabajo Práctico 3

2do Cuatrimestre, 2026

MEMORÁNDUM INTERNO

De: Dirección de Confianza y Seguridad (Trust & Safety) — RedBaires S.A.

Para: Equipo de Análisis Cuantitativo

Asunto: Dinámica de difusión de rumores en la plataforma y evaluación de contramedidas

Fecha: 15 de septiembre de 2026

Clasificación: Confidencial — uso interno

Hola Equipo,

Los convocamos porque necesitamos entender, y sobre todo anticipar, cómo se propaga un rumor dentro de RedBaires, y qué palancas nos conviene mover para contenerlo sin destruir el negocio. Lo que sigue es todo el contexto que pudimos reunir del incidente reciente, de cómo funciona hoy nuestra operación, y de lo que observamos en nuestros propios datos. Al final encontrarán las decisiones que la Dirección necesita tomar y las condiciones bajo las cuales su trabajo será aceptado. Les pedimos que nos ayuden a estructurar este problema: buena parte de la información está redactada en la jerga interna del equipo y no vamos a poder acompañarlos campo por campo.

1. La plataforma

RedBaires es la red social de mayor penetración en la región del Río de la Plata. Operamos desde 2013, con unos 19,4 millones de usuarios activos mensuales y cerca de 7,8 millones de usuarios activos diarios. El 85% de nuestros ingresos proviene de publicidad, que facturamos esencialmente por *impresiones* servidas: cada vez que una pieza de contenido se muestra a un usuario, ese *alcance* tiene un valor económico. Dicho de otro modo, todo lo que circula (incluido el contenido nocivo) genera ingreso, y ésta es exactamente la tensión que nos trae hasta acá.

El contenido circula por cuatro superficies: el Muro (el feed principal, ordenado por nuestro algoritmo de recomendación), los Grupos, las Historias (contenido efímero que expira a las 24 horas) y los Mensajes Directos. La probabilidad de que una pieza se vuelva a compartir depende, entre otras cosas, de la superficie: no se reenvía igual algo visto en un grupo que algo recibido por mensaje privado. Un usuario reenvía («recompartir», en nuestra jerga) hacia su propia audiencia de seguidores, y así el contenido salta de una persona a la siguiente formando lo que internamente llamamos una cascada de difusión.

2. El incidente del 14 de junio

El sábado 14 de junio, cerca del mediodía, una cuenta de gran alcance publicó una **afirmación falsa**: que la billetera virtual «PagoYá» había congelado los fondos de sus usuarios por un supuesto pedido judicial. La afirmación era completamente infundada. En cuestión de horas, el contenido (primero un texto, luego una captura de pantalla y

una placa con formato de meme) se compartió de forma explosiva. Para la tarde del domingo, PagoYá reportaba una ola de retiros y cierres de cuenta; el lunes, el episodio había escalado a los medios tradicionales y a una consulta formal de la Secretaría de Servicios Digitales.

Cuando reconstruimos lo ocurrido encontramos un patrón que ya habíamos visto, más chico, en episodios anteriores: el disparador fue una sola cuenta de enorme audiencia, y en las primeras horas la amplificación estuvo dominada por un conjunto de cuentas que publicaban de forma casi sincronizada, con patrones que no parecen orgánicos. El grueso de nuestros usuarios se sumó después, cuando el rumor ya era tendencia. Tres días más tarde, el tema estaba prácticamente muerto: dejó de recompartirse aunque el contenido seguía disponible.

El Directorio fue tajante: no podemos permitirnos otro 14 de junio. Nos pidió una recomendación fundada sobre qué medidas adoptar antes del próximo episodio, con una estimación honesta de su costo y de su efectividad. Y nos pidió, sobre todo, que no adivinemos: que lo modelemos.

3. Lo que observamos sobre cómo se propagan los rumores

A lo largo de los últimos meses, el equipo de Ciencia de Datos fue acumulando observaciones sobre la dinámica de difusión. No tenemos una teoría cerrada (ése es, en parte, el encargo), pero sí una lista de regularidades que consideramos robustas:

- La enorme mayoría de los rumores se apagan solos en pocas horas y no llegan a nadie relevante. Sin embargo, una fracción ínfima escapa a todo control y alcanza a millones. La distribución del tamaño de las cascadas es extrema: no se parece en nada a una campana; hay muchísimos episodios diminutos y unos poquísimos gigantescos que concentran casi todo el alcance.
- Cada recompartir dispara, en promedio, una cierta cantidad de recompartires posteriores. Ese «factor de multiplicación» es la variable que más nos preocupa: cuando se mantiene por debajo de cierto umbral, el rumor se extingue; cuando lo supera, la difusión crece sola y se nos va de las manos. No terminamos de ponernos de acuerdo en cómo estimarlo bien a partir de los datos.
- No todas las cuentas pesan igual. Un puñado de cuentas de gran audiencia concentra una porción desproporcionada del alcance. Internamente segmentamos a los creadores por tamaño de audiencia en cuatro niveles —nano, micro, macro y mega—, pero no tenemos claro cuánto pesa realmente cada nivel en que un rumor prenda o no. Lo que sí notamos es que el efecto no es proporcional: una cuenta con cien veces más seguidores no genera cien veces más reenvíos.
- El contenido tiene una «vida útil». Cada pieza parece tener un tiempo característico tras el cual el ritmo de reenvíos se desploma —algo así como una vida media—, incluso si sigue estando visible. Algunos temas mueren en minutos; otros persisten días.
- La probabilidad de reenvío no es fija. Depende de quién publicó, del formato (un video corto o una placa tipo meme no rinden igual que un enlace externo), de la superficie, y de cuán «fresco» esté el contenido. En nuestros registros no guardamos esa probabilidad como tal; habría que deducirla.

Distribución variable alcance

Estimar factor multiplicador de recompartir

Peso según nivel de cuenta

Distribución variable tiempo de reenvíos

- **La actividad no es pareja en el tiempo.** Hay ráfagas, y además picos y valles según la hora del día y el día de la semana. Un rumor sembrado a las cuatro de la mañana de un martes no se comporta como uno sembrado un sábado a la tarde.
- **Sospechamos amplificación coordinada.** Creemos que parte del alcance proviene de *redes de cuentas que actúan de forma coordinada e inauténtica*, pero no las tenemos identificadas: no hay una etiqueta que diga «esta cuenta es de una granja». Solo contamos con señales indirectas y ninguna es concluyente por sí sola.

4. Cómo funciona hoy nuestra operación de moderación

Cuando una pieza de contenido entra en circulación, nuestro **clasificador automático** (lo llamamos “Centinela”) la evalúa y le asigna un **puntaje de nocividad** y **una o más etiquetas**. Las etiquetas provienen de DISARM, un marco internacional de técnicas de desinformación cuyos códigos usamos tal cual (no vamos a explicarlos acá; forman parte de lo que deberán interpretar). El contenido que Centinela marca entra en una **cola de moderación**, que en principio se atiende por orden de llegada.

En la práctica, sin embargo, la cola **no es un FIFO puro**. Nuestros moderadores tienden a ser más indulgentes con las cuentas verificadas y con los clientes históricos, y más severos con ciertos temas sensibles. **La probabilidad de que una pieza termine efectivamente removida no es uniforme: depende del tema y del puntaje de nocividad**. Y hay una **latencia**: entre que una pieza se marca y que se actúa sobre ella puede pasar desde minutos hasta varias horas, y ese tiempo importa muchísimo, porque mientras tanto el contenido se sigue propagando. Una pieza removida deja de generar nuevas exposiciones; una que se remueve tarde ya hizo su daño.

5. Cuentas, audiencias y señales

La **distribución de seguidores** entre nuestras cuentas es brutalmente desigual: la **mediana ronda los pocos cientos de seguidores**, pero **tenemos cuentas con millones**. Una **fracción de las cuentas está verificada**, lo que se **correlaciona fuertemente con el tamaño de audiencia**. **Clasificamos internamente** a las cuentas por su **rol** — difusores masivos, creadores, reposteadores, cuentas durmientes, cuentas estándar—, y esa **clasificación no coincide** exactamente con los **niveles de audiencia**; son dos cosas distintas.

niveles de
audiencia
!=
clasificación

Sobre las cuentas que sospechamos **coordinadas**: lo poco que sabemos es que suelen ser **relativamente nuevas**, que comparten ciertos **rasgos técnicos de dispositivo**, y que se agrupan alrededor de **determinados identificadores de campaña**. Insistimos: **ninguna de estas señales, por sí sola, alcanza para acusar a una cuenta**. Quien quiera distinguir lo coordinado de lo orgánico va a tener que combinar varias señales débiles y asumir el riesgo de equivocarse.

6. Los datos que les entregamos

Les entregamos **dos archivos**. El primero, **muestra_cascadas_REDBAIRES.csv**, es un volcado crudo de nuestro registro de eventos de propagación: **66.153 filas, cada una un evento (una publicación original o un reenvío), agrupadas en 5.000 cascadas**. Es un export directo del sistema, **no un dataset prolijo**: van a encontrar campos con

valores faltantes, inconsistencias de formato, registros duplicados y valores anómalos. Peor aún: perdimos la documentación de los campos en una rotación del equipo de datos, así que tendrán que interpretar qué significa cada columna a partir de su nombre, de sus valores y de lo que puedan investigar por fuera. Consideramos que reconstruir e interpretar correctamente esos campos es parte del trabajo.

El segundo archivo, `parametros_y_costos.csv`, reúne los parámetros económicos y de costos que Finanzas pudo estimar: lo que vale una impresión legítima, el costo de un moderador, el costo de desarrollar y operar el clasificador, la penalización reputacional de moderar de más, la externalidad social de una impresión nociva no contenida, la pérdida de *engagement* asociada a poner fricción, y demás. Cada parámetro viene con un rango plausible: van a necesitarlo.

7. Las decisiones que necesitamos tomar

El Directorio evalúa tres palancas para contener el próximo episodio, y necesita saber cuál —o qué combinación, y con qué intensidad— conviene adoptar. Ninguna es gratis:

- **Ampliar la capacidad de moderación** (más moderadores, un mejor clasificador, o ambos). Reduce la exposición al contenido nocivo, pero cuesta dinero y, si nos pasamos, moderamos de más y molestamos a usuarios legítimos.
- **Poner fricción a los reenvíos** (limitar cuántas veces se puede recompartir una pieza, al estilo del límite de reenvíos que ya aplicaron otras plataformas). Frena la propagación, pero también recorta el *engagement* legítimo del que vivimos.
- **Degradar el alcance** («bajar en el ranking») de las cuentas de mayor audiencia y/o de las redes coordinadas que logremos detectar. Puede ser quirúrgico, pero tiene costo reputacional y de negocio, y depende de qué tan bien identifiquemos a quién degradar.

Las preguntas que la Dirección quiere ver respondidas, con números y no con opiniones, son: ¿conviene adoptar cada una de estas medidas? ¿En qué intensidad? ¿Cuál es el costo-beneficio de cada una y cuál rinde más por cada peso invertido? La recomendación final debe indicar, de manera inequívoca, qué haría el equipo en nuestro lugar y por qué. Nos importa especialmente entender bajo qué condiciones una medida que hoy parece cara se vuelve imprescindible (y viceversa).

8. Condiciones del encargo

No vamos a experimentar con medidas nuevas directamente sobre 19 millones de usuarios: sería temerario. Por eso la Dirección quiere un modelo que nos permita ensayar los escenarios antes de tocar la plataforma y ver cómo se comportaría la difusión bajo cada medida. Ese modelo es el corazón del entregable, y tiene que cumplir las condiciones de nuestra área de Ingeniería de Simulación, que son innegociables:

- Nuestra área de Simulación sólo integra modelos de eventos discretos construidos a nivel del diagrama principal y subprocessos. No aceptamos modelos basados en agentes individuales por usuario: nuestra base

tenemos que ver
qué combinación
de estas 3 elegimos

no se modelan
usuarios individuales



es demasiado grande para instanciar una entidad por persona, y esa arquitectura no corre en nuestro entorno.

- Por las mismas restricciones de cómputo, el modelo no puede generar una cantidad de entidades que crezca sin control con el tamaño de la difusión. Un prototipo que anda con datos de juguete pero colapsa cuando el rumor escala no nos sirve. Queremos ver, explícitamente, que el consumo se mantiene acotado incluso en el peor escenario.

tiene que ser escalable (para posts de distinta escala)

- El modelo debe ser reproducible y permitir cambiar los supuestos con facilidad. La Dirección no quiere un único número: quiere ver un rango de resultados (al menos un escenario conservador, uno intermedio y uno pesimista) y entender qué tan sensible es la conclusión a los supuestos.

de base, IC

- No adoptaremos un modelo que no reproduzca lo que ya observamos en nuestros propios registros. Si su simulación no genera cascadas con una forma y una dispersión parecidas a las de los datos que les dimos, para nosotros no es creíble, por elegante que sea.

debe parecerse a los datos que nos dan

- La recomendación se defenderá ante el comité. Esperen preguntas sobre por qué el modelo se comporta como lo hace, pedidos de justificar cada supuesto y de recalcular en vivo cambiando alguno. No aceptamos cajas negras: si no pueden explicar de dónde sale un resultado, no lo vamos a usar.

Toda decisión de modelado que tomen (y van a tener que tomar muchas) debe quedar registrada y justificada, con la mejor referencia técnica que encuentren o, en su defecto, con un razonamiento explícito. Suerte; sabemos que no es un encargo fácil.

— Dirección de Confianza y Seguridad, RedBaires S.A.

Objetivos contrapuestos: minimizar el costo de